



Caso Práctico: Limpieza del Conjunto de Datos del Titanic

🎯 Objetivo

Limpiar las columnas clave del conjunto de datos del Titanic para que puedan ser utilizadas en un análisis o modelo estadístico.

Dataset de Origen

El archivo CSV del Titanic generalmente contiene columnas como:

Columna	Tipo de Dato	Problema Común para Limpieza
Survived	Numérico (0/1)	Generalmente limpio, pero sirve de referencia.
Pclass	Numérico (1, 2, 3)	Generalmente limpio.
Name	Texto	Inconsistencias o datos extraídos (títulos).
Sex	Texto	Inconsistencias de mayúsculas/minúsculas.
Age	Numérico (Decimal)	Muchos valores faltantes ().
Fare	Numérico (Decimal)	Pequeño número de valores faltantes y <i>outliers</i> .
Cabin	Texto	Demasiados valores faltantes (más del 70%).
Embarked	Texto	Pequeño número de valores faltantes.



✂ Tareas de Limpieza Identificadas (Solo Limpieza)

El proceso de limpieza se centrará en manejar la información incompleta o inconsistente.

1. Manejo de Valores Faltantes (NaN / Null)

- **Columna Age (Edad):**
 - **Problema:** Contiene muchos valores faltantes ().
 - **Solución de Limpieza Sencilla: Imputar** (rellenar) los valores faltantes con la **mediana** de la columna. La mediana es más robusta a los valores atípicos que la media.
- **Columna Embarked (Puerto de Embarque):**
 - **Problema:** Contiene muy pocos valores faltantes.
 - **Solución de Limpieza Sencilla:** Imputar los valores faltantes con el **valor más frecuente** (la moda) de la columna.
- **Columna Cabin (Cabina):**
 - **Problema:** Demasiados valores faltantes (la mayoría de las filas).
 - **Solución de Limpieza Sencilla: Eliminar la columna completa**, ya que tiene muy poca utilidad analítica debido a la cantidad de datos faltantes.

2. Estandarización de Formato y Eliminación de Ruido

- **Columna Sex (Género):**
 - **Problema:** Podría contener inconsistencias de mayúsculas/minúsculas (Male, male, Female, female).
 - **Solución de Limpieza Sencilla:** Convertir todos los valores a **minúsculas** (male, female) para unificar el formato.
- **Columna Name (Nombre):**
 - **Problema:** Contiene títulos y nombres muy largos que no son útiles para el análisis.
 - **Solución de Limpieza Sencilla:** Extraer y crear una nueva columna (Title) con los **títulos** de las personas (ej: 'Mr.', 'Mrs.', 'Miss.') y luego **eliminar la columna Name** original, ya que los nombres completos no añaden valor predictivo.

3. Conversión de Tipo de Dato

- **Columna Fare (Tarifa):**
 - **Problema:** Algunos *datasets* pueden tener esta columna como texto (string) si hay símbolos de moneda.
 - **Solución de Limpieza Sencilla:** Asegurar que el tipo de dato sea **numérico** (flotante).



Entregables

Entregable 1: Informe de Limpieza de Datos (Formato Documento/Word)

Este documento debe justificar la necesidad de cada paso de limpieza y demostrar visualmente su ejecución y resultado.

I. Estructura del Documento

1. **Título y Portada:** Caso Práctico: Limpieza del Conjunto de Datos del Titanic.
2. **Introducción:**
 - Definición del Objetivo de la limpieza.
 - Justificación de la importancia de la fase de limpieza de datos.
 - Realización de los métodos de la librería panda (shape, columns, head, info, entre otras) representando su salida
3. **Metodología de Limpieza Detallada:** (El cuerpo principal del informe)
 - Sección 1: Manejo de Valores Faltantes (NaN / Null).
 - Sección 2: Estandarización de Formato y Eliminación de Ruido.
 - Sección 3: Conversión de Tipo de Dato.
4. **Conclusión:** Resumen del estado final del conjunto de datos (Por ejemplo: el dataset final contiene [N] columnas y [M] filas, listo para el análisis exploratorio de datos (EDA) o la construcción de modelos.).

Entregable 2: Código Fuente en Python (Archivo .py o Jupyter Notebook)

Este entregable es el código ejecutable que permite a cualquier usuario replicar el proceso de limpieza y obtener el *dataset* final.

I. Estructura del Código

1. **Importación de Librerías:** Solo las necesarias (pandas, numpy).
2. **Carga del Dataset:** Código para cargar el archivo (ej. `pd.read_csv('titanic.csv')`) y otros métodos de panda
3. **Bloques de Limpieza:** El código debe estar organizado en bloques que sigan la estructura del informe.
 - Bloque 1: Manejo de Valores Faltantes.
 - Bloque 2: Estandarización y Ruido.
 - Bloque 3: Conversión de Tipo de Dato.
4. **Comentarios (Muy Importante):** Cada línea o bloque de código debe tener comentarios claros (#) que expliquen qué se está haciendo y por qué. Esto es crucial para la legibilidad del código.
5. **Verificación Final:** El código debe terminar con comandos de verificación para mostrar el estado final del *dataframe* limpio.



II. Comandos de Verificación Requeridos

El final del código debe ejecutar los siguientes comandos para demostrar que la limpieza fue exitosa:

- `df.info()`: Para demostrar que las columnas (Age, Embarked, Fare) ya no tienen valores nulos y que Cabin fue eliminada.
- `df.head()`: Para mostrar las primeras filas, verificando la presencia de la nueva columna Title y la estandarización de Sex.
- `df.isnull().sum()`: Para confirmar que no quedan valores faltantes en las columnas que se debían imputar.

Fecha de entrega: 03-11-2025

Valor: 25%

Entrega individual

Un recordatorio clave: antes de cualquier limpieza, dediquen tiempo a inspeccionar a fondo su dataset utilizando los métodos de Pandas. Conocer sus datos es el primer paso para un análisis exitoso.