

Asignación de Machine Learning: Modelos Predictivos en Python

Caso de Estudio 1: Sector Inmobiliario (Regresión Lineal Simple)

Objetivo: Predecir el precio de una propiedad basándose en su tamaño.

Código en Python

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression

# 1. Datos: Metros Cuadrados vs Precio (Miles de USD)
data = {
    'Metros_Cuadrados': [45, 60, 85, 120, 150, 50, 75, 90, 110, 130, 160,
40],
    'Precio_USD': [120, 155, 210, 310, 390, 135, 190, 230, 280, 340, 410,
110]
}
df = pd.DataFrame(data)

# 2. Preparación y División
X = df[['Metros_Cuadrados']]
y = df['Precio_USD']
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42)

# 3. Entrenamiento
modelo_casa = LinearRegression()
modelo_casa.fit(X_train, y_train)

# --- EJEMPLO DE PREDICCIÓN ---
metros_nuevos = np.array([[105]])
prediccion = modelo_casa.predict(metros_nuevos)
print(f"PREDICCIÓN: Un inmueble de 105 m² costaría aproximadamente:
${prediccion[0]:.2f} USD")
```

Caso de Estudio 2: Marketing y Redes Sociales

Objetivo: Predecir el número de "Likes" que recibirá una publicación según los minutos invertidos en su diseño.

Código en Python

```
import pandas as pd
from sklearn.linear_model import LinearRegression

# 1. Datos: Minutos de Diseño vs Likes Recibidos
data = {
    'Minutos_Diseño': [10, 20, 30, 40, 50, 60, 70, 80, 90, 100],
    'Likes': [15, 25, 45, 55, 62, 80, 85, 110, 125, 140]
}
```

```
df_social = pd.DataFrame(data)

X_social = df_social[['Minutos_Diseño']]
y_social = df_social['Likes']

# 2. Entrenamiento
modelo_social = LinearRegression()
modelo_social.fit(X_social, y_social)

# --- EJEMPLO DE PREDICCIÓN ---
minutos_input = [[45]]
likes_predichos = modelo_social.predict(minutos_input)
print(f"PREDICCIÓN: Con 45 min de diseño, se esperan
{int(likes_predichos[0])} likes.")
```

Cuestionario de Justificación Técnica

Instrucciones: Responde de forma clara y justifica cada respuesta basándote en la teoría de Machine Learning y el código proporcionado.

1. ¿Por qué usamos `df[['Metros_Cuadrados']]` (con doble corchete) para definir la variable X?
2. En el Caso 1, si cambiamos `test_size=0.2` por `test_size=0.8`, ¿qué impacto tendría en la confiabilidad del entrenamiento?
3. ¿Para qué sirve el parámetro `random_state=42` en la función `train_test_split`?
4. Si el coeficiente R^2 del modelo de casas fuera de 0.98, ¿podemos decir que el modelo es perfecto? Explica el concepto de varianza.
5. Observa el Caso 2: ¿Por qué no se utilizó `train_test_split`? ¿Qué consecuencia tiene esto al reportar la precisión del modelo?
6. En la ecuación $y = mx + b$, ¿qué representa físicamente la pendiente (m) en el contexto del Caso de Estudio 2 (Likes)?
7. Si al predecir para 105 m² el resultado es 270 USD, pero el precio real en el mercado es 300 USD, ¿cómo se le llama a esa diferencia en Machine Learning?
8. ¿Qué sucedería si intentamos predecir el precio de una mansión de 5,000 m² con el modelo actual? Justifica basándote en el rango de los datos.
9. Según las mejores prácticas del material, ¿cuál sería el siguiente paso si el R^2 de nuestro modelo es muy bajo (ejemplo: 0.30)?

Caso práctico a desarrollar: Análisis de Crecimiento Salarial Profesional

Contexto: Un portal de empleo necesita un algoritmo que permita a los candidatos estimar qué salario podrían negociar según sus años de experiencia. Utilizarás un dataset real para entrenar un modelo de Machine Learning que aprenda esta relación financiera.

1. Instrucciones de Preparación

Para esta práctica, no usaras datos manuales. Debes seguir estos pasos:

1. Descarga el archivo llamado Salary_Data.csv.
2. Coloca el archivo en la misma carpeta donde crearás tu script de Python (o súbelo a tu entorno de Google Colab).
3. Desarrolla el Código en Python

Fecha de entrega: Viernes 23 de enero de 2026